


ToxicGuard V5.2 — Model Analiz Raporu

XLM-RoBERTa-base | Focal Loss | EN + TR | 293K Egitim Verisi

Versiyon Karsilastirmasi — F1-Macro (Optimize Threshold)



0.7478

F1-Macro

0.9769

ROC-AUC

293K

Egitim Verisi

Etiket Bazli F1 Skorlari (Optimize Threshold ile)




Optimize Threshold Degerleri


Etiket	Threshold	F1@0.5	F1@Opt
toxic	0.40	0.8678	0.8877
severe_toxic	0.30	0.0594	0.4303
obscene	0.40	0.7773	0.8249
threat	0.45	0.7382	0.7489
insult	0.40	0.7517	0.7824
identity_hate	0.40	0.7794	0.8129

693 Yorum Genis Test Seti — Kategori Bazli Dogruluk

Kategori Dogruluk Oranlari



Genel Seviye Dagilimi (693 yorum)



Kategori Detay Tablosu

Kategori	Toplam	Guvenli	Dikkat	Toksik	Acc
Clean	153	144 (94.1%)	9 (5.9%)	0 (0%)	%94.1
Explicit Toxic	223	0 (0%)	20 (9%)	203 (91%)	%91.0
Friendly Prof.	157	22 (14%)	65 (41.4%)	70 (44.6%)	%55.4
Impl. Sarcasm	160	35 (21.9%)	124 (77.5%)	1 (0.6%)	%99.4

ONEMLI BULGULAR

GUCLU YONLER:

Implicit Sarcastic → %99.4
Model ortuk toksisiteyi neredeyse hic kacimiyor, 'Dikkat' seviyesinde dogru yakalamaktadır.

Clean (Temiz) → %94.1
0 yorum yanlis 'Toksik' dedi. False positive yok.

KRITIK PROBLEM:

Friendly Profanity → %55.4
157 ornekten 70'i yanlis Toksik sayildi. Sebep: Model kelime bazli karar veriyor, baglamlari okuyamiyor.

Ornekler:

'sick fuck' → otomatik Toksik
'serefsiz' → otomatik Toksik
'crazy bastard' → otomatik Toksik

Kritik Yanlis Siniflandirmalar — False Positive & False Negative

Modelin en cok hata yaptigi ornekler

FALSE POSITIVE: Dostane/Argo ama Toksik Sayilanlar (Beklenen: Guvenli/Dikkat, Model: TOKSIK)


Yorum	Skor	Model	Beklenen
This database schema is insanely good, you sick fuck!	0.880	TOKSIK	Guvenli
Ulan şerefsiz, bu proje köpek gibi hızlı!	0.878	TOKSIK	Guvenli
Ulan şerefsiz, bu proje dehşet bir şey olmuş!	0.878	TOKSIK	Guvenli
Ulan şerefsiz, bu sistem manyak çalışıyor!	0.873	TOKSIK	Guvenli
Ulan şerefsiz, bu entegrasyon manyak çalışıyor!	0.869	TOKSIK	Guvenli
Ulan şerefsiz, bu güncelleme hayvan gibi iyi!	0.868	TOKSIK	Guvenli
Ulan şerefsiz, bu kod hayvan gibi iyi!	0.862	TOKSIK	Guvenli
Vay anasını satayım, bu kod manyak çalışıyor!	0.860	TOKSIK	Guvenli
Vay anasını satayım, bu sistem manyak çalışıyor!	0.857	TOKSIK	Guvenli

FALSE NEGATIVE: Acik Toksik ama Kacirilanlari (Beklenen: TOKSIK, Model: Dikkat/Guvenli)

Yorum	Skor	Model	Beklenen
What a fucking moron and it shows.	0.393	Dikkat	TOKSIK
Absolutely a worthless joke for doing this.	0.401	Dikkat	TOKSIK
Absolutely a worthless joke and it shows.	0.413	Dikkat	TOKSIK
What a fucking loser and it shows.	0.437	Dikkat	TOKSIK
What a fucking loser for doing this.	0.438	Dikkat	TOKSIK
What a fucking idiot and it shows.	0.477	Dikkat	TOKSIK
Sen tam bir vasıfsız bir karaktersin, boş yapma.	0.512	Dikkat	TOKSIK
Cidden vasıfsız bir insansın, boş yapma.	0.513	Dikkat	TOKSIK
Absolutely a disgusting joke for doing this.	0.525	Dikkat	TOKSIK

300 Yorum Gelismis Test Seti — Bolum Analizi

300 Yorum — Bolum Bazli Tahmini Basari



Sarkazm Testi: 9/10 Dogru (%80)



En Yuksek Skor Alabilen "Güvenli" Örnekler

Güvenli ama model yüksek skor verdi:
(Küçük de olsa false positive riski)

0.300 This pull request highlights a complete failure...

0.297 You have a unique talent for turning a five-...

0.296 Your latest commit shows why you shouldn't be...

0.296 This database schema is fucking incredible, you...

0.290 This pull request shows a profound lack of basic...

0.287 Yaptığın bu analiz mantıksızlığının ne kadar...

Ozet ve Onerilerin —Sonraki Adimlar

Model Performans Ozeti

EGITIM METRIKLERI

F1-Macro (opt. threshold)	:	0.7478
F1-Macro (default 0.5)	:	0.6623
ROC-AUC	:	0.9769
Egitim verisi	:	293.364 ornek
Dil	:	EN + TR
Model	:	XLM-RoBERTa-base (278M)
Epoch	:	3
Loss fonksiyonu	:	Focal Loss (gamma=2)

ETIKET BAZLI F1 (Opt. Threshold):

toxic	:	0.8877	✓
obscene	:	0.8249	✓
identity_hate	:	0.8129	✓
insult	:	0.7824	✓
threat	:	0.7489	✓
severe_toxic	:	0.4303	x (nadir sinif)

693 YORUM TEST SONUCLARI:

Clean	:	%94.1	✓
Explicit Toxic	:	%91.0	✓
Impl. Sarcasm	:	%99.4	✓
Friendly Prof.	:	%55.4	x (ana sorun)

300 YORUM SARKAZM TESTI:

10 ornek uzerinden	:	8/10 (%80)	✓
--------------------	---	------------	---

Tespit Edilen Sorunlar ve Onerilen Cozumler

SORUN 1: Friendly Profanity (%55.4)

Model 'sick fuck', 'serefzis', 'crazy bastard' gibi kufurleri gorununce baglamdan bagimsiz Toksik koyuyor.

Oneri → V6: Two-Stage Cascade Model

Model A: Toxicity
(mevcut V5.2)
+
Model B: Context Classifier
(SARC + dostane ornekler)
↓
Combiner Logic → Final Karar

SORUN 2: severe_toxic dusuk (0.4303)

Egitim verisinde nadir sinif. Jigsaw Bias datasında sadece 494 ornek.

Oneri → Oversampling veya daha fazla 'severe_toxic' iceren veri toplamak.

SORUN 3: Turkce argo tutarsizligi

'Urefsiz' + teknik terim → toksik
Ama 'ulan kopek' bazen temiz diyor.

Oneri → Daha fazla TR argo baglam verisi (Eksi Sozluk, Twitter TR).